ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ

BÁO CÁO THỰC TẬP

NGÀNH: CÔNG NGHỆ THÔNG TIN

ĐỀ TÀI:

DATA ENGINEERING FOR AXIOM PLATFORM

Giảng viên hướng dẫn:	**TS. Nguyễn Thu Trang**
Sinh viên:	**Trần Minh Nam**
Mã sinh viên:	**23021646**
Lớp:	**K68I - CS4**

Hà Nội, tháng 9 năm 2026

LỜI CẢM ƠN

Lời đầu tiên, em xin gửi lời cảm ơn chân thành tới cô TS. Nguyễn Thu Trang và thầy TS. Nguyễn Văn Sơn đã hướng dẫn, định hướng nghiên cứu và góp ý cho em trong quá trình thực hiện đề tài. Các góp ý của thầy cô giúp em rất nhiều trong việc thực hiện và hoàn thiện quá trình nghiên cứu và báo cáo dự án thực tập này.

Em cũng xin gửi lời cảm ơn tới các thầy cô, anh chị và các bạn trong nhóm nghiên cứu Intelligent Software Engineering (iSE) đã hỗ trợ em rất nhiều về kiến thức chuyên môn trong quá trình thực hiện đề tài. Em xin cảm ơn nhóm dự án AXIOM Data Engineering, gồm các bạn Trần Mạnh Tân, Vũ Hải Đăng, Thân Đăng Khôi và chị Nguyễn Hà Linh, đã cùng em trao đổi, phản biện và xây dựng giải pháp trong suốt thời gian qua.

Cuối cùng, em xin chân thành cảm ơn các thầy cô đang công tác và giảng dạy tại Trường Đại học Công nghệ, Đại học Quốc gia Hà Nội đã tạo điều kiện thuận lợi để em được học tập, thực tập và phát triển đề tài này.

Hà Nội, tháng 9 năm 2026

Sinh viên

Trần Minh Nam

LỜI CAM ĐOAN

Em là Trần Minh Nam, sinh viên lớp K68I-CS4, ngành Công nghệ Thông tin, Trường Đại học Công nghệ, Đại học Quốc gia Hà Nội. Em xin cam đoan những nội dung trình bày trong báo cáo thực tập với đề tài "Data Engineering for AXIOM Platform" là kết quả công việc do em trực tiếp thực hiện trong khuôn khổ dự án AXIOM Data Engineering, dưới sự hướng dẫn của cô TS. Nguyễn Thu Trang.

Toàn bộ số liệu và kết quả thực nghiệm trong báo cáo được đo trên bộ khung đánh giá của nhóm và được trình bày trung thực. Phần công việc do các thành viên khác trong nhóm thực hiện được ghi rõ ở mục II.c. Các nội dung tham khảo từ tài liệu khác đều được ghi rõ nguồn trích dẫn. Em xin chịu trách nhiệm về lời cam đoan này.

Hà Nội, tháng 9 năm 2026

Sinh viên

Trần Minh Nam

MỤC LỤC

LỜI CẢM ƠN **2**
LỜI CAM ĐOAN **3**
MỤC LỤC **4**
I. Giới thiệu chung **5**
a. Giới thiệu công việc 5
b. Giới thiệu qua bài toán 6
II. Yêu cầu bài toán **6**
a. Mô tả bài toán tổng thể 6
b. Quy trình tổng thể và phần việc của em 7
c. Phân chia công việc trong nhóm 8
III. Tóm tắt lý thuyết, giải pháp, thuật toán **9**
a. Các lý thuyết, giải pháp, thuật toán liên quan 9
1. Retrieval văn bản 9
2. Truy xuất theo cấu trúc tài liệu và DISRetrieval 10
3. Visual document retrieval và reranking 11
b. Phương pháp đề xuất 12
1. Quy trình truy xuất cơ sở (Baseline Pipeline) 12
2. Cải thiện chất lượng truy vấn 13
c. Liên hệ và so sánh với các cách tiếp cận đã có 15
IV. Mô tả phần mềm cài đặt **15**
a. Môi trường và cách cài đặt 15
b. Cách sử dụng và tái lập kết quả 16
V. Kết quả đạt được và hướng phát triển **16**
a. Kết quả đạt được 16
1. Dữ liệu và phương pháp đánh giá 16
2. Lựa chọn chiến lược chunking 17
3. Chất lượng retrieval 18
4. Chi phí và thời gian chạy 20
b. Hạn chế của giải pháp hiện tại 22
c. Hướng phát triển tiếp theo 22
d. Kỹ năng và kiến thức thu thập được 23
TÀI LIỆU THAM KHẢO **24**

I. Giới thiệu chung

a. Giới thiệu công việc

Trong kỳ thực tập, em tham gia dự án AXIOM Data Engineering thuộc nhóm Nghiên cứu và Phát triển (R&D) của nền tảng AXIOM. Mục tiêu cốt lõi của nền tảng là cho phép doanh nghiệp truy vấn thông tin bằng ngôn ngữ tự nhiên trên toàn bộ kho tài liệu nội bộ, đồng thời nhận về câu trả lời luôn đi kèm bằng chứng xác thực. Yêu cầu truy vết bằng chứng này chính là điểm quan trọng của AXIOM bởi trong môi trường doanh nghiệp, một hệ thống không thể truy rõ nguồn gốc câu trả lời sẽ không đảm bảo độ tin cậy để đưa vào vận hành thực tế.

Về mặt kiến trúc, hệ thống được cấu thành từ hai giai đoạn chính bao gồm giai đoạn trích xuất bằng chứng (retrieval pipeline) và giai đoạn tổng hợp câu trả lời dựa trên bằng chứng (generation pipeline). Trong dự án này, em chịu trách nhiệm thiết kế và triển khai hai module cốt lõi thuộc giai đoạn đầu, gồm module phân mảnh - nhúng vector (chunking-embedding) và module truy xuất thông tin (retrieval). Cụ thể, module chunking-embedding tiếp nhận các tài liệu đã qua bóc tách cấu trúc để phân đoạn và chuyển đổi thành biểu diễn vector ngữ nghĩa, còn module retrieval chịu trách nhiệm khai thác hệ thống chỉ mục đa phương thức nhằm xác định và xếp hạng các trang tài liệu chứa bằng chứng xác đáng nhất cho câu hỏi của người dùng.

Các kết quả nghiên cứu chính đạt được bao gồm:

1. Xây dựng module chunking-embedding và thực nghiệm giúp chứng minh cấu hình phân mảnh cố định giúp cắt giảm từ 46,0% đến 87,5% số lượng vector cần lưu trữ so với phân mảnh theo ngữ nghĩa mà không làm suy giảm độ chính xác.
2. Phân tích định lượng nguyên nhân lỗi trong hệ thống cơ sở, chứng minh rằng sự sụt giảm hiệu năng chủ yếu bắt nguồn từ việc suy giảm thứ hạng các trang mục tiêu (ranking loss) thay vì không tìm thấy ứng viên (candidate loss).
3. Đề xuất thuật toán lan truyền bằng chứng theo cấu trúc tài liệu (Structural Evidence Propagation - SEP) kết hợp cùng nhánh truy xuất tài liệu thị giác (visual document retrieval), qua đó nâng chỉ số NDCG@10 từ 43,45 lên 53,15 điểm trên tập dữ liệu chuẩn.
4. Xây dựng cơ chế mã hóa ảnh trang theo yêu cầu (on-demand encoding) kết hợp bộ nhớ đệm, giúp rút ngắn thời gian khởi tạo phản hồi đầu tiên từ xấp xỉ 40 phút xuống còn dưới 6 phút trên kho dữ liệu thử nghiệm.

b. Giới thiệu qua bài toán

Với một kho tài liệu doanh nghiệp quy mô lớn cùng một câu hỏi bất kỳ bằng ngôn ngữ tự nhiên, bài toàn của hệ thống là cần truy xuất danh sách các trang tài liệu chứa đầy đủ bằng chứng. Danh sách này đóng vai trò là ngữ cảnh được cung cấp cho mô hình ngôn ngữ lớn ở khâu sinh câu trả lời. Do đó, chất lượng của câu trả lời cuối cùng phụ thuộc trực tiếp vào độ chính xác và độ phủ của quá trình truy xuất. Trong môi trường doanh nghiệp, bài toán thường gặp hai thách thức chính:

- **Tính phức tạp của định dạng dữ liệu**: Tài liệu doanh nghiệp tồn tại dưới nhiều định dạng đa dạng như tài liệu PDF kỹ thuật số, tài liệu quét (scanned PDF), tệp hình ảnh, slides thuyết trình hay bảng tính. Đáng chú ý, các thông tin định lượng quan trọng thường nằm trong bảng biểu, biểu đồ hoặc sơ đồ cấu trúc. Các phương pháp bóc tách văn bản truyền thống thường làm thất thoát hoặc biến dạng cấu trúc không gian của những dữ liệu trực quan này.
- **Ràng buộc độ trễ và khả năng mở rộng**: Các kho lưu trữ nội bộ thường có dung lượng rất lớn. Trong khi đó, các tác vụ tính toán chuyên sâu như phân tích cấu trúc tài liệu, tính toán vector nhúng và đặc biệt là mã hóa hình ảnh qua các mạng thị giác lớn đều đòi hỏi chi phí tính toán và thời gian thực thi đáng kể. Hệ thống không thể xử lý trước toàn bộ kho dữ liệu một cách tốn kém nếu muốn đáp ứng thời gian đưa vào vận hành thực tế.

II. Yêu cầu bài toán

a. Mô tả bài toán tổng thể

Module Data Engineering tiếp nhận đầu vào gồm kho tài liệu đa định dạng của doanh nghiệp và câu truy vấn ngôn ngữ tự nhiên từ người dùng. Đầu ra của module là danh sách k = 10 trang tài liệu có độ liên quan cao nhất kèm theo định danh tệp và số thứ tự trang, phục vụ làm ngữ cảnh cho khâu sinh phản hồi.

Hệ thống phải thỏa mãn bốn yêu cầu kỹ thuật nền tảng:

1. **Khả năng truy vết nguồn gốc bằng chứng:** Mọi phần thông tin được sử dụng để tổng hợp câu trả lời phải được liên kết chính xác tới một trang tài liệu cụ thể của một tệp tin xác định.
2. **Tính độc lập với định dạng đầu vào**: Mọi nguồn tài liệu thô sau khi tiếp nhận đều được chuẩn hóa về một cấu trúc dữ liệu trung gian thống nhất là Uniform Intermediate Representation (Uniform IR). Mỗi khối nội dung trong Uniform IR đều lưu trữ metadata về tệp tin và số trang gốc. Nhờ cấu trúc này, việc tích

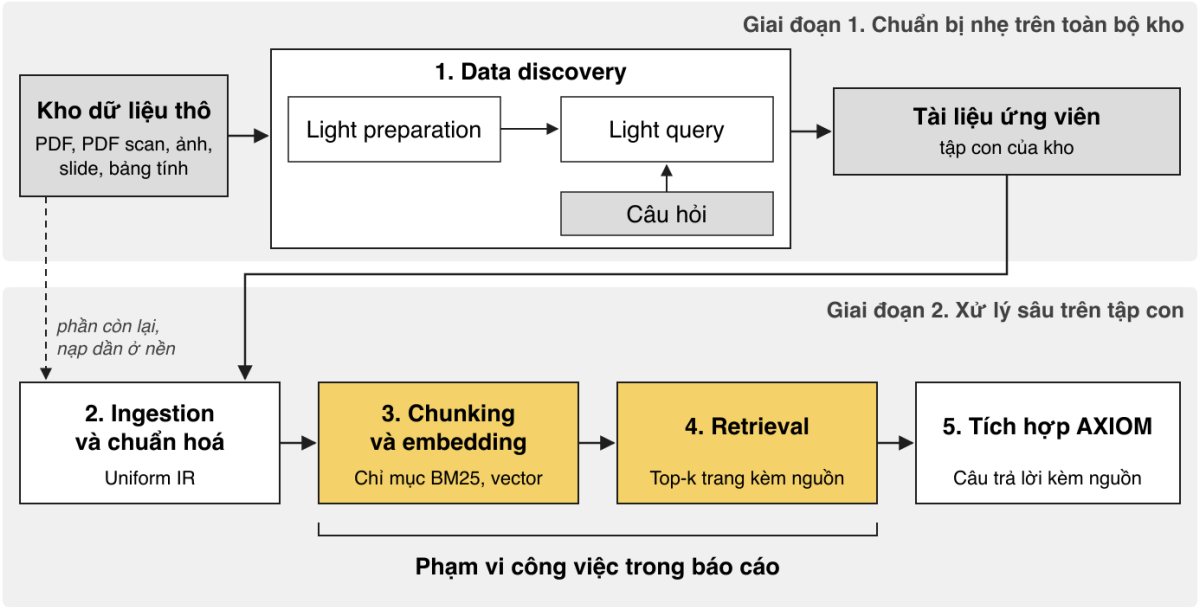
hợp thêm các định dạng tài liệu mới chỉ yêu cầu mở rộng bộ chuyển đổi ở tầng ingestion mà không làm thay đổi các tầng xử lý phía sau.

3. **Cân bằng giữa chi phí tính toán và độ trễ phục vụ**: Hiệu năng tính toán của hệ thống được lượng hóa qua ba chỉ số chính: chi phí trích xuất ngoại tuyến (offline indexing cost là thời gian xử lý toàn bộ kho dữ liệu trước khi nhận truy vấn đầu tiên), trung bình thời gian phản hồi truy vấn đầu (*T_first*) và trung bình độ trễ phục vụ trực tuyến (*t_q*). Hệ thống cần tối ưu hóa để đảm bảo *T_first* ở mức ngắn nhất có thể và duy trì *t_q* ở ngưỡng chấp nhận được trong môi trường thời gian thực.
4. **Tương thích với hạ tầng sản phẩm**: Các thuật toán đề xuất phải có khả năng suy luận trên nền tảng CPU thông qua các môi trường runtime chuẩn bao gồm PyTorch 2.2.2 và ONNX Runtime. Các thành phần sử dụng mạng nơ-ron sâu đòi hỏi tăng tốc phần cứng (GPU) phải được cô lập thành các dịch vụ độc lập.

Chất lượng xếp hạng và các thông số thời gian phản hồi được đo lường chuẩn hóa trên tập đánh giá ViDoRe V3 [1].

b. Quy trình tổng thể và phần việc của em

Quy trình Data Engineering gồm năm module nối tiếp nhau, chia thành hai giai đoạn như trong Hình 1.



Hình 1. Quy trình xử lý dữ liệu của nền tảng AXIOM và phạm vi công việc

1. **Giai đoạn chuẩn bị nhẹ trên toàn kho (Data Discovery):** Ở giai đoạn chuẩn bị nhẹ, module data discovery nhận kho dữ liệu thô cùng câu hỏi của người dùng và trả ra *Kf* tài liệu ứng viên, trong đó *Kf* là số tài liệu giữ lại cho mỗi câu hỏi. Để chạy đủ nhanh trên toàn bộ kho, module chỉ đọc lớp văn bản của PDF

bằng thư viện pdf-inspector rồi lọc bằng BM25 (thuật toán xếp hạng dựa trên tần suất từ khoá) và không gọi mô hình nặng nào. Yêu cầu quan trọng nhất của module này là độ phủ cao, bởi tài liệu nào bị loại ở đây thì các module phía sau không thể tìm lại được. Các module sau sẽ hoạt động trực tiếp trên tập con này, còn phần dữ liệu còn lại được nạp dần ở chế độ nền.

2. **Giai đoạn xử lý chuyên sâu trên tập ứng viên:** Với đầu vào là tập tài liệu con đã được lọc ra từ giai đoạn trước, module ingestion dùng KDL (một vision-language model nhỏ đọc trực tiếp ảnh từng trang) để parsing các tài liệu được chọn, rồi chuẩn hoá kết quả về Uniform IR. Mỗi phần nội dung trong Uniform IR, dù là văn bản, đề mục, bảng hay hình, đều mang theo tệp và số trang nguồn để kết quả cuối cùng truy vết được. Từ Uniform IR, module chunking và embedding chia nội dung thành các chunk, tính vector embedding cho từng chunk và trả ra hai chỉ mục là chỉ mục BM25 và chỉ mục vector. Module retrieval dùng hai chỉ mục này cùng với ảnh trang để chấm điểm, rồi trả ra top-k trang kèm tệp và số trang nguồn. Cuối cùng, module tích hợp AXIOM đóng gói thành phần retrieval thành một dịch vụ độc lập chạy trên môi trường hiện có của nền tảng.

Trong năm module, em phụ trách module chunking và embedding cùng module retrieval, được đánh dấu trong Hình 1. Đây là phần được trình bày chi tiết trong báo cáo, gồm các lý thuyết liên quan ở mục III.a, phương pháp đề xuất ở mục III.b và kết quả ở mục V.a.

c. Phân chia công việc trong nhóm

Dự án gồm năm thành viên. Bảng 1 tổng hợp phân công công việc của từng thành viên trong nhóm

Bảng 1. Phân công công việc trong nhóm

Thành viên	Mã sinh viên & LHP	Mảng phụ trách
Trần Minh Nam	23021646 (K68I-CS4)	Chịu trách nhiệm chính về kiến trúc module chunking-embedding và module retrieval; đề xuất thuật toán SEP và cơ chế on-demand encoding.
Trần Mạnh Tân	24021619 (K69I-CS3)	Phối hợp thử nghiệm các chiến lược chunking và retrieval; trực tiếp giám sát, quản lý và vận hành hệ thống đánh giá thực nghiệm.

Thành viên	Mã sinh viên & LHP	Mảng phụ trách
Vũ Hải Đăng	23020042 (K68I-IT3)	Xây dựng pipeline xử lý nhanh dữ liệu thô (light preparation), module ingestion và chuẩn hóa Uniform IR.
Thân Đăng Khôi	24020185 (K69I-IT5)	Phát triển module data discovery, ingestion và quy trình xử lý theo luồng on-demand.
Nguyễn Hà Linh	22024505 (K67I-IS)	Đóng gói và tích hợp pipeline vào nền tảng sản phẩm AXIOM.

III. Tóm tắt lý thuyết, giải pháp, thuật toán

a. Các lý thuyết, giải pháp, thuật toán liên quan

1. Retrieval văn bản

Truy xuất thông tin (Information Retrieval - IR) giải quyết bài toán định vị và sắp thứ tự các đơn vị nội dung trong một tập hợp tài liệu lớn dựa trên mức độ liên quan tới câu hỏi q. Hệ thống truy xuất truyền thống gồm hai thành phần cơ bản là hàm đo điểm tương đồng giữa câu hỏi và đoạn văn bản, cùng cấu trúc chỉ mục tương ứng giúp tối ưu hóa tốc độ tìm kiếm. Hai hướng tiếp cận chủ yếu hiện nay gồm:

- **Truy xuất từ vựng (Lexical Retrieval)**: Dựa trên mức độ trùng khớp từ vựng giữa câu hỏi và văn bản. Thuật toán tiêu biểu là BM25, hoạt động dựa trên tần suất xuất hiện của từ khóa, tần suất nghịch đảo của từ trong toàn bộ kho dữ liệu (IDF) và độ dài tương đối của đoạn văn. BM25 có ưu thế tìm kiếm đối với các thuật ngữ kỹ thuật đặc thù, mã định danh, số liệu chính xác nhưng sẽ không thể phát hiện được những từ đồng nghĩa hoặc cách diễn đạt biến thể so với câu hỏi.
- **Truy xuất ngữ nghĩa (Dense Retrieval)**: Sử dụng các mô hình ngôn ngữ mã hóa (bi-encoder) để ánh xạ câu hỏi và đoạn văn bản vào cùng một không gian vector đa chiều, trong đó độ tương đồng ngữ nghĩa được đo bằng khoảng cách cosine. Hướng tiếp cận này có thể bắt trọn ngữ nghĩa trừu tượng và thường được kết hợp với truy xuất từ vựng để có thể bao phủ cả hai mặt từ vựng và ngữ nghĩa.

Để đưa văn bản vào các mô hình mã hóa có độ dài cửa sổ giới hạn, tài liệu cần được chia thành các phân mảnh nhỏ (chunks). Các chiến lược chunking phổ biến gồm:

- **Fixed-size chunking:** Cắt đoạn văn bản theo số lượng từ hoặc token cố định kèm khoảng chồng lấn (overlap) giữa các đoạn kế tiếp. Phương pháp này có độ phức tạp thuật toán thấp nhất.
- **Structural chunking:** Phân mảnh dựa theo ranh giới tự nhiên của văn bản như đoạn văn, tiêu đề mục hoặc bảng dữ liệu do bộ phân tích cú pháp trích xuất.
- **Semantic chunking:** Xác định điểm ngắt phân đoạn tại vị trí độ tương đồng ngữ nghĩa giữa các câu liền kề giảm đột ngột.
- **Hierarchical chunking:** Xây dựng cây phân cấp tóm tắt nhiều tầng, tiêu biểu như kiến trúc RAPTOR [12].

Nghiên cứu của Barnett và cộng sự [11] đã chỉ ra rằng chiến lược semantic chunking thường không bù đắp được chi phí tính toán tăng thêm trong thực tế, trong khi hierarchical chunking đòi hỏi chi phí suy luận mô hình ngôn ngữ lớn quá cao ngay từ giai đoạn lập chỉ mục.

Khi việc chấm điểm được thực hiện trên đơn vị chunk nhưng kết quả đầu ra yêu cầu theo đơn vị trang, thuật toán MaxP (Maximum Passage) được áp dụng phổ biến bằng cách lấy giá trị điểm cao nhất của các chunk nằm trong trang làm điểm đại diện cho trang đó:

$$s_page(q, c) = max_\{x \in c\}\ s_chunk(q, x)$$

Cuối cùng, hybrid retrieval kết hợp điểm của hai cách tiếp cận trên. Vì điểm BM25 và điểm cosine có thang đo rất khác nhau, điểm của mỗi nhánh được chuẩn hoá min-max theo từng truy vấn [8], rồi hai nhánh được cộng có trọng số với tham số alpha nằm trong đoạn [0, 1].

$$s_norm(c) = [s(c) - min\ s(c')] / [max\ s(c') - min\ s(c')]$$

$$s_hybrid(c) = alpha \cdot s_dense(c) + (1 - alpha) \cdot s_bm25(c)$$

2. Truy xuất theo cấu trúc tài liệu và DISRetrieval

Các mô hình truyền thống thường xem xét các đoạn văn bản một cách độc lập mà bỏ qua mối quan hệ thứ bậc trong tài liệu. Để khắc phục, một số nghiên cứu gần đây biểu diễn tài liệu dưới dạng cây phân cấp, trong đó các nút lá lưu giữ văn bản gốc, còn các nút nội tại đại diện cho ngữ cảnh bao hàm của các nhánh con.

Điển hình cho hướng tiếp cận này là DISRetrieval [2], một phương pháp áp dụng Lý thuyết Cấu trúc Diễn ngôn (Rhetorical Structure Theory - RST) để biểu diễn quan hệ logic ngữ nghĩa giữa các câu (như quan hệ giải thích, đối lập, liệt kê) thành một cây diễn ngôn (discourse tree). DISRetrieval gồm ba giai đoạn:

1. Dựng cây diễn ngôn bằng một bộ phân tích cú pháp diễn ngôn (discourse parser) chuyên biệt.
2. Sử dụng mô hình ngôn ngữ lớn (Llama-3.1-8B) để tóm tắt thông tin từ các nút lá lên các nút cha theo cơ chế bottom-up, sau đó mã hóa toàn bộ các nút thành vector.
3. Tiến hành tìm kiếm phân cấp: khi một nút cha có độ liên quan cao với truy vấn, hệ thống sẽ tự động ưu tiên trích xuất các câu thành phần thuộc nhánh con của nó.

Mặc dù mang lại hiệu năng cao trên các tập dữ liệu dài, DISRetrieval tồn tại ba nhược điểm lớn khi áp dụng vào doanh nghiệp: chi phí tính toán ngoại tuyến cực kỳ đắt đỏ (mất khoảng 103 giây GPU cho một tài liệu 50.000 từ), phụ thuộc lớn vào chất lượng của mô hình discourse parser vốn chỉ được huấn luyện trên ngữ liệu báo chí tiếng Anh, và chỉ xử lý được các cấu trúc văn bản liên tục, không tương thích với bảng biểu hay tài liệu giàu hình ảnh.

3. Visual document retrieval và reranking

Để giải quyết bài toán mất mát thông tin khi bóc tách các trang chứa nhiều định dạng trực quan (biểu đồ, sơ đồ), hướng tiếp cận truy xuất tài liệu thị giác (Visual Document Retrieval) ra đời với các kiến trúc tiêu biểu như ColPali [6], ColEmbed [4] và ColVec [5]. Phương pháp này loại bỏ khâu OCR và parsing bằng cách xử lý trực tiếp ảnh chụp của toàn bộ trang tài liệu thông qua các mô hình thị giác ngôn ngữ.

Các mô hình trên áp dụng cơ chế tương tác muộn (late interaction). Trang tài liệu được chia thành lưới các vùng ảnh (patches) và mã hóa thành một ma trận vector. Tương tự, câu truy vấn được biểu diễn bằng một tập các vector token. Điểm liên quan giữa câu hỏi q và trang p được tính toán thông qua toán tử MaxSim:

$$MaxSim(q, p) = \Sigma_{t \in q} max_{v \in p} \langle q_t, v \rangle$$

Trong đó:

- *MaxSim(q, p)*: Điểm số tương đồng giữa truy vấn q và trang tài liệu p.
- q: Tập hợp các vector đại diện cho truy vấn.
- p: Tập hợp các vector đại diện cho nội dung hình ảnh của trang p.
- t: Một token (thành phần) cụ thể trong truy vấn q.
- q_t: Vector biểu diễn của token t.
- v: Một mảnh ảnh (image patch) cụ thể trong trang p.
- v_v: Vector biểu diễn của mảnh ảnh v.
- $<q_t, v_v>$: Tích vô hướng (dot product) giữa vector token truy vấn và vector mảnh ảnh, thể hiện mức độ khớp giữa chúng.

Toán tử MaxSim tìm kiếm vùng ảnh có mức độ tương đồng cao nhất cho từng token trong câu hỏi và tổng hợp lại. Rào cản lớn nhất của mô hình thị giác là chi phí suy luận và không gian lưu trữ vector rất lớn. Một số nghiên cứu như LightSTAR [19] hay AgenticOCR [20] đã hướng tới việc lọc sơ bộ để giảm bớt số lượng trang cần xử lý qua mô hình nặng.

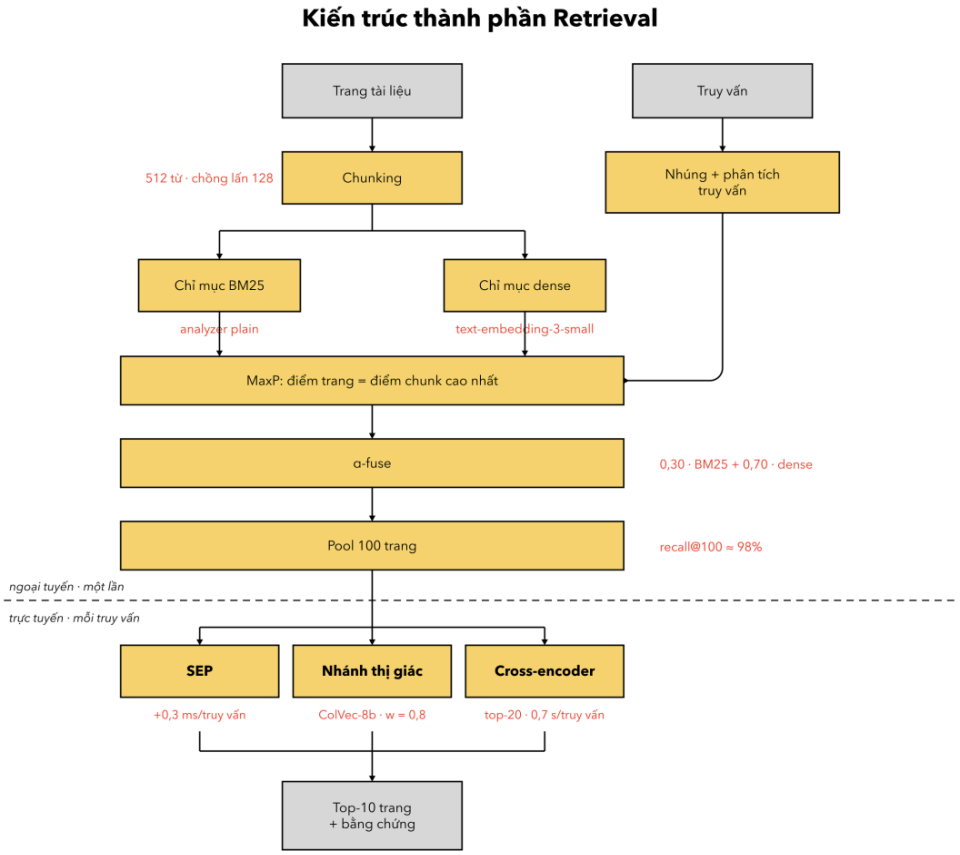
Bên cạnh đó, kỹ thuật chấm điểm lại (Reranking) sử dụng mô hình cross-encoder thường được sử dụng ở tầng cuối. Khác với cơ chế bi-encoder mã hóa độc lập, cross-encoder tiếp nhận đồng thời cả văn bản câu hỏi và nội dung trang để mô hình hóa sự tương tác qua cơ chế self-attention đầy đủ. Mặc dù cho độ chính xác cao, cross-encoder làm gia tăng đáng kể độ trễ trực tuyến do phải chạy mô hình trực tiếp trên từng cặp ứng viên.

b. Phương pháp đề xuất

1. Quy trình truy xuất cơ sở (Baseline Pipeline)

Quy trình truy xuất cơ sở được chuẩn hóa trên đơn vị trang nhằm tối ưu hóa tính truy vết nguồn gốc bằng chứng. Kiến trúc tổng thể được biểu diễn tại Hình 2.

- **Giai đoạn ngoại tuyến:** Mỗi trang tài liệu sau khi được bóc tách sẽ trải qua khâu phân mảnh kích thước cố định 512 từ, chồng lấn 128 từ (được lựa chọn thông qua thực nghiệm tại mục V.a.2). Các phân đoạn văn bản được đồng thời mã hóa thành vector 1536 chiều bằng mô hình text-embedding-3-small và nạp vào chỉ mục từ vựng BM25.
- **Giai đoạn trực tuyến:** Khi có câu hỏi, hệ thống tiến hành chấm điểm song song trên cả hai chỉ mục. Điểm số của các chunk được ánh xạ về cấp độ trang thông qua toán tử *MaxP*, sau đó được chuẩn hóa min-max và hợp nhất theo công thức tuyến tính với trọng số *alpha* = 0,70 cho nhánh dense và 0,30 cho nhánh BM25. Top 100 trang có điểm số cao nhất được chọn làm tập ứng viên phục vụ cho các thuật toán tái xếp hạng phía sau.



Hình 2. Kiến trúc thành phần retrieval chia thành giai đoạn offline và online

2. Cải thiện chất lượng truy vấn

Phân tích lỗi trên hệ thống cơ sở (mục V.a.3) cho thấy: 98,3% các câu hỏi đều có ít nhất một trang bằng chứng nằm trong tập ứng viên 100 trang, nhưng chỉ số Recall@10 chỉ đạt 46,36%. Điều này khẳng định sự sụt giảm chất lượng chủ yếu xuất phát từ hiện tượng suy giảm thứ hạng (ranking loss). Cụ thể, hệ thống gặp hai dạng lỗi xếp hạng:

- **Lỗi định vị trang trong cùng tài liệu:** Hệ thống xác định đúng tài liệu chứa câu trả lời nhưng lại xếp sai trang mục tiêu.
- **Lỗi thất thoát thông tin trực quan:** Các trang chứa bằng chứng dạng biểu đồ, sơ đồ bị chấm điểm thấp do khâu bóc tách văn bản không phản ánh được đầy đủ thông tin.

Để giải quyết triệt để hai dạng lỗi này, phương pháp đề xuất hai cơ chế:

Cơ chế 1: Thuật toán lan truyền bằng chứng theo cấu trúc (SEP)

Để khắc phục lỗi định vị trang, phương pháp đề xuất thuật toán SEP (Structural Evidence Propagation) nhằm kế thừa tư tưởng lan truyền ngữ cảnh của DISRetrieval.

Ý tưởng chính là các trang gold evidence sẽ thường nằm cạnh nhau, chúng ta sẽ gán một hệ số điểm và thực hiện cơ chế tính điểm theo cấu trúc như DISRetrieval cho hàng xóm của mỗi trang. Cuối cùng, điểm cấu trúc sẽ tổng hợp lại và sắp xếp độ liên quan của các trang. Với mỗi trang ứng viên *c* trong tập pool, điểm số mới được hiệu chỉnh theo công thức:

$$s'(c) = \lambda \cdot s(c) + (1 - \lambda) \cdot [\, \beta \cdot A_file(c) + (1 - \beta) \cdot N(c) \,]$$

Trong đó:

- *s(c)* là điểm số kết hợp ban đầu của trang sau khi chuẩn hóa.
- *A_file(c)* là điểm đại diện của tài liệu chứa trang *c*, được tính bằng trung bình cộng điểm số của 3 trang có điểm cao nhất thuộc cùng tài liệu đó trong pool. Việc dùng giá trị trung bình thay vì tổng giúp loại bỏ hiện tượng thiên vị đối với các tài liệu có số trang quá dài.
- *N(c)* là tín hiệu lan truyền từ các trang lân cận trong phạm vi bán kính 2 trang, với trọng số phân rã theo hàm lũy thừa 0,5 mũ khoảng cách.
- Các siêu tham số được cố định qua thực nghiệm: $\lambda = 0{,}5$ và $\beta = 0{,}75$. Trọng số β ưu tiên tín hiệu cấp tài liệu do số liệu phân tích chứng minh độ tương quan đồng tài liệu mạnh hơn đáng kể so với tương quan lân cận. Do chỉ thực hiện các phép toán đại số cơ bản trên các điểm số đã tính toán, SEP bổ sung độ trễ không đáng kể (+0,3 ms), không phụ thuộc GPU và không làm thay đổi cấu trúc chỉ mục sẵn có.

Cơ chế 2: Bổ sung nhánh truy xuất trực quan (Visual Branch)

Nhằm xử lý các trang giàu thông tin hình ảnh, hệ thống tích hợp thêm một nhánh truy xuất trực tiếp trên ảnh chụp trang. Các trang tài liệu được render thành ảnh độ phân giải 144 DPI từ tệp PDF gốc, không qua OCR. Toàn bộ ảnh trang được mã hóa bởi mô hình late-interaction webAI-ColVec1.1-8b [5] (một mô hình truy xuất thị giác chuyên biệt và hàng đầu hiện nay), và tính điểm với câu hỏi thông qua toán tử *MaxSim*. Điểm số từ nhánh thị giác được chuẩn hóa độc lập và hợp nhất cùng nhánh văn bản với trọng số 0,8 dành cho thị giác.

3. Tối ưu hóa chi phí vận hành bằng kỹ thuật mã hóa theo yêu cầu

Hạn chế lớn nhất của nhánh thị giác là thời gian mã hóa toàn bộ kho tài liệu trước khi phục vụ rất lớn (mất xấp xỉ 1,2 giây/trang trên GPU L4). Để loại bỏ nút thắt này,

em phát triển quy trình mã hóa theo yêu cầu (on-demand visual encoding) gồm hai bước:

- **Thu hẹp phạm vi qua Data Discovery:** Khi nhận câu hỏi, hệ thống sử dụng module data discovery để lọc nhanh ra K_f tài liệu ứng viên dựa trên lớp văn bản thô sẵn có. Nhánh thị giác chỉ cần mã hóa các trang thuộc tập K_f tài liệu này thay vì toàn bộ kho.
- **Cơ chế lưu đệm động (Dynamic Caching):** Hệ thống không mã hóa ảnh trước mà thực hiện suy luận ngay khi có truy vấn yêu cầu, sau đó lưu trữ các vector trang vào bộ nhớ đệm (cache).

c. Liên hệ và so sánh với các cách tiếp cận đã có

Khác với RAPTOR hay DISRetrieval đòi hỏi bước tiền xử lý đắt đỏ bằng các mô hình LLM trên GPU (103 đến 338,5 giây cho 50.000 từ), phương pháp SEP tận dụng cây phân cấp cấu trúc tự nhiên sẵn có từ metadata tệp tin, hoàn toàn không phát sinh chi phí tính toán ngoại tuyến và áp dụng được cho mọi định dạng tài liệu. Điểm đánh đổi là cây phân cấp của SEP chỉ có hai tầng, do đó khi áp dụng trên các tài liệu kỹ thuật dài hàng trăm trang, tín hiệu cấp tài liệu có thể bị phân tán, đòi hỏi các ngưỡng kích hoạt phù hợp.

Đối với nhánh truy xuất thị giác, thay vì sử dụng mô hình thị giác làm bộ truy xuất độc lập hoàn toàn như các nghiên cứu gốc của ColPali hay ColVec, hệ thống thiết lập cơ chế kết hợp song song đa phương thức. Hơn nữa, phương pháp mã hóa theo yêu cầu có nét tương đồng với tư tưởng lọc thô của LightSTAR [19] và AgenticOCR [20], nhưng ưu việt hơn ở chỗ tái sử dụng trực tiếp module data discovery sẵn có của hệ thống ở cấp độ tài liệu mà không cần huấn luyện thêm bất kỳ thành phần định tuyến nào.

IV. Mô tả phần mềm cài đặt

a. Môi trường và cách cài đặt

Hệ thống được viết bằng Python 3.11 trở lên. Môi trường được quản lý bằng Conda, và các gói phụ thuộc được cài bằng pip theo lệnh sau.

```
conda env create -f environment.yml && pip install -e .
```

Các mô hình chạy trên máy cục bộ dùng PyTorch 2.2.2 và ONNX Runtime (mục II.a). Mô hình embedding văn bản và mô hình sinh được gọi qua OpenRouter, một dịch vụ cho phép gọi nhiều mô hình qua cùng một API. Khoá API của OpenRouter được khai báo trong tệp .env.

b. Cách sử dụng và tái lập kết quả

Toàn bộ thực nghiệm được chạy qua giao diện dòng lệnh (CLI). Module retrieval nhận đầu vào là kết quả parsing ở dạng Uniform IR và trả ra danh sách top-k trang kèm tệp và số trang nguồn. Chiến lược chunking, bộ embedding và các cơ chế xếp hạng đều được chọn qua tham số dòng lệnh. Lệnh dựng các chỉ mục offline (chunk, chỉ mục BM25 và chỉ mục vector) cho một lần chạy như sau, trong đó --analyzer chọn cách tách từ cho chỉ mục BM25.

```
python -m src.retrieval.build_artifacts \
    --run-id <RUN_ID> --analyzer auto
```

Lệnh chạy đánh giá quy trình cơ sở như sau, trong đó --arms liệt kê các cấu hình cần so sánh (chỉ BM25, chỉ dense và tổ hợp với alpha = 0,7) và --k là số trang trả về.

```
python -m src.evaluation.run_retrieval \
    --benchmark vidore_v3 --subset physics --language french \
    --arms bm25,dense,alpha0.7 --embedder openrouter_te3s --k 10
```

Lệnh tái lập cấu hình có chất lượng cao nhất ở Bảng 3, gồm SEP và ColVec-8b, như sau, trong đó --visual-dir trỏ tới thư mục chứa kết quả mã hoá ảnh trang và --wv là trọng số của nhánh visual.

```
python research/experiments/physics_kdl_slate.py \
    --parse pdf-inspector \
    --visual-dir data/work/vidore_physics_colvec \
    --visual-name colvec --wv 0.8
```

Việc mã hoá ảnh trang bằng ColVec-8b được chạy trên Colab và Kaggle, vì máy cục bộ không có GPU chuyên dụng.

V. Kết quả đạt được và hướng phát triển

a. Kết quả đạt được

1. Dữ liệu và phương pháp đánh giá

Chất lượng retrieval được đánh giá trên bộ benchmark ViDoRe V3 [1], gồm các tài liệu PDF thực tế thuộc nhiều lĩnh vực, trong đó mỗi câu hỏi được gán sẵn các trang chứa bằng chứng cùng mức độ liên quan. Các thực nghiệm chính được chạy trên tập con physics bằng tiếng Pháp, gồm 302 câu hỏi trên 1.674 trang của 42 tài liệu chuyên ngành. Trung bình mỗi tài liệu dài 39,9 trang và mỗi câu hỏi có 7,2 trang đúng. Bốn tập con khác là pharmaceuticals (dược phẩm), hr (nhân sự), industrial (công nghiệp) và computer_science (khoa học máy tính) có độ dài tài liệu rất khác nhau, nên được dùng để kiểm tra hành vi của SEP trên những miền dữ liệu khác. Riêng việc chọn chiến lược chunking được đánh giá trên ba bộ dữ liệu hỏi đáp văn bản là QASPER (bài báo khoa học), UIT-ViQuAD (hỏi đáp đọc hiểu tiếng Việt) và ISE Challenge (kho dữ liệu đa định dạng của cuộc thi iSE Summer Challenge 2026).

Chất lượng xếp hạng được đo bằng *NDCG@10* (Normalized Discounted Cumulative Gain tại 10) có phân cấp. Ý tưởng của thước đo này là một danh sách tốt phải đặt các trang liên quan nhất lên đầu. *NDCG@10* cộng điểm liên quan của 10 trang đầu, nhưng trang ở vị trí càng thấp thì điểm càng bị giảm bớt. Tổng này sau đó được chia cho tổng lớn nhất có thể đạt được khi các trang được xếp theo thứ tự lý tưởng (*IDCG@10*), nên kết quả nằm trong khoảng từ 0 đến 1; báo cáo nhân với 100 cho dễ đọc. Ví dụ, cùng tìm được hai trang đúng, danh sách đặt chúng ở hạng 1 và 2 sẽ có *NDCG@10* cao hơn hẳn danh sách đặt chúng ở hạng 8 và 9.

$$NDCG@10 = DCG@10 / IDCG@10$$

$$DCG@10 = \Sigma_{i=1}^{10} (2^{rel_i} - 1) / log_2(i + 1)$$

Trong đó, *rel_i* là mức độ liên quan của trang ở vị trí thứ i.

Bên cạnh *NDCG@10*, báo cáo dùng *Recall@10,* tức tỉ lệ trang đúng xuất hiện trong 10 trang đầu.

$$Recall@10 = |C_{true} \cap C_{retrieved}^{10}| / |C_{true}|$$

Trong đó, *C_true* là tập trang đúng của câu hỏi, còn *C_retrieved^10* là 10 trang có điểm cao nhất mà hệ thống trả về.

Chi phí được đo bằng ba đại lượng đã định nghĩa ở mục II.a là chi phí offline, *T_firs*t và *t_q*. Để kiểm tra mức tăng của retrieval có chuyển thành câu trả lời tốt hơn hay không, em còn chạy đánh giá end-to-end: mô hình sinh DeepSeek-V4-Flash nhận top 10 trang làm ngữ cảnh để viết câu trả lời, rồi GPT-4o đối chiếu câu trả lời với đáp án để xếp vào mức chính xác hoàn toàn, đúng một phần hoặc sai.

Để các so sánh được công bằng, mọi cấu hình retrieval đều dùng chung một kết quả parsing từ pdf-inspector và KDL, cùng bộ câu hỏi và cùng các thước đo trên, nên chênh lệch giữa các cấu hình chỉ đến từ thành phần retrieval. Riêng thời gian chạy của chế độ mã hoá theo yêu cầu (mục V.a.4) được mô phỏng từ các hằng số đo thực tế trên GPU NVIDIA L4, chưa được đo trên hệ thống thật.

2. Lựa chọn chiến lược chunking

Kết quả đối sánh giữa phương pháp semantic chunking và phương pháp fixed-size chunking (kích thước 512 từ, độ chồng lấn 128 từ) trên ba tập dữ liệu chuẩn được thống kê tại Bảng 2.

Bảng 2. So sánh semantic chunking và fixed-size chunking

Bộ dữ liệu	Chiến lược	Recall@10	Thay đổi tương đối	Số chunk	Thay đổi số chunk
QASPER	Semantic	17,01%	—	4.115	—
QASPER	Fixed 512, overlap 128	18,85%	+10,8%	2.221	−46,0%
UIT-ViQuAD	Semantic	44,36%	—	2.183	—
UIT-ViQuAD	Fixed 512, overlap 128	46,32%	+4,4%	559	−74,4%
ISE Challenge	Semantic	61,22%	—	104.927	—
ISE Challenge	Fixed 512, overlap 128	60,21%	−1,7%	13.114	−87,5%

Số liệu tại Bảng 2 chỉ ra rằng fixed-size chunking vượt trội hoàn toàn về mặt tối ưu chi phí lưu trữ: số lượng vector nhúng giảm từ 46,0% đến 87,5% trên cả ba bộ dữ liệu. Về độ chính xác, phương pháp kích thước cố định đạt Recall@10 cao hơn trên QASPER (+10,8%) và UIT-ViQuAD (+4,4%), đồng thời chỉ giảm nhẹ không đáng kể 1,7% trên tập ISE Challenge. Thực nghiệm này xác nhận kết luận của Barnett và cộng sự [11] về tính thiếu hiệu quả về mặt chi phí của semantic chunking, qua đó chứng minh tính đúng đắn khi lựa chọn fixed-size chunking làm cấu hình mặc định cho nền tảng.

3. Chất lượng retrieval

Như đã nói ở phần III.b.2, phân tích lỗi cho thấy hai vấn đề chính trong retrieval baseline pipeline. Đó là hệ thống xác định đúng tài liệu chứa câu trả lời nhưng lại xếp sai trang mục tiêu và việc các bằng chứng thị giác chưa được bóc tách chính xác phục và chuyển thành thành phần có thể được retrieve. Và đây là các căn cứ thực nghiệm quyết định trực tiếp đến thiết kế của SEP và nhánh visual như bàn ở phần III.b.2.

Hiệu năng chi tiết của các cấu hình nâng cấp được tổng hợp tại Bảng 3.

Bảng 3. Kết quả retrieval và chi phí vận hành trên 302 câu hỏi

Phương pháp	NDCG@10	Recall@10	Thay đổi NDCG@10	Online mỗi truy vấn	Chi phí offline
Baseline Pipeline	43,45	46,36	—	21,7 ms	1h 23m
Kết hợp SEP	45,52	48,24	+2,08 điểm (+4,8%)	22,0 ms (+0,3 ms)	1h 23m
Kết hợp rerank Nemotron	47,42	48,95	+3,98 điểm (+9,2%)	721,7 ms (+700 ms)	1h 23m

Phương pháp	NDCG@10	Recall@10	Thay đổi NDCG@10	Online mỗi truy vấn	Chi phí offline
Kết hợp visual ColQwen2-2B	47,00	49,50	+3,55 điểm (+8,2%)	22,7 ms (+1,0 ms)	1h 38m (+15m GPU)
Kết hợp SEP và ColQwen2-2B	47,73	50,71	+4,28 điểm (+9,9%)	23,0 ms (+1,3 ms)	1h 38m (+15m GPU)
Kết hợp visual ColVec-8b	51,73	56,16	+8,28 điểm (+19,1%)	23,0 ms (+1,3 ms)	1h 58m (+35m GPU)
Kết hợp SEP và ColVec-8b	**53,15**	**55,91**	**+9,70 điểm (+22,3%)**	**23,3 ms (+1,6 ms)**	**1h 58m (+35m GPU)**

Cấu hình tối ưu kết hợp giữa thuật toán SEP và nhánh thị giác ColVec-8b đạt kết quả cao nhất với 53,15 điểm NDCG@10, tăng 22,3% tương đối so với hệ thống cơ sở, trong khi độ trễ truy vấn trực tuyến chỉ tăng thêm 1,6 ms. Nhánh visual đóng vai trò quyết định khi đóng góp tới 19,1% cải thiện. Ngược lại, dù mô hình cross-encoder Nemotron mang lại mức tăng 9,2%, nó làm bùng nổ độ trễ trực tuyến lên thêm 700 ms mỗi truy vấn (gấp hơn 30 lần thời gian của toàn bộ pipeline cơ sở), do đó không phù hợp để đưa vào môi trường sản phẩm thực tế. Thay vào đó, việc sử dụng tính điểm lan truyền cấu trúc bằng SEP để sắp xếp lại ứng viên cho mức tăng ổn định (4,8%) và không hề làm hệ thống chậm lại, cho thấy sự phù hợp khi kết hợp với nhánh thị giác để thích hợp mục đích sử dụng trực tuyến của người dùng.

Hiệu quả của thuật toán SEP theo độ dài tài liệu được trình bày tại Bảng 4.

Bảng 4. Thay đổi NDCG@10 khi thêm SEP trên các tập con của ViDoRe V3

Tập con	Số trang trung bình mỗi tài liệu	Tỉ lệ trang đúng trên độ dài tài liệu	Thay đổi NDCG@10	Thay đổi tương đối
physics	39,9	14,6%	+2,02	+4,7%
pharmaceuticals	44,5	12,0%	+2,17	+4,9%
hr	79,3	9,5%	+0,54	+1,0%
industrial	194,2	5,2%	−0,14	−0,3%
computer_science	680,0	0,8%	−0,09	−0,2%

Số liệu chỉ ra rằng thuật toán SEP đạt hiệu quả rõ rệt nhất trên các tập tài liệu có độ dài dưới 50 trang (tỷ lệ trang bằng chứng chiếm trên 10% chiều dài tài liệu). Đối với các tài liệu dài hàng trăm trang (tập industrial và computer_science), tín hiệu cấp tài liệu A_{file} bị pha loãng dần về mức trung bình của toàn bộ tệp, khiến

SEP mất khả năng phân biệt. Do đó, quy tắc vận hành rút ra là chỉ kích hoạt SEP khi kho dữ liệu có độ dài trung bình ở quy mô ngắn và vừa.

Bảng 5 phản ánh kết quả thử nghiệm đánh giá chất lượng sinh câu trả lời đầu - cuối (End-to-End).

Bảng 5. Kết quả đánh giá end-to-end trên 302 câu hỏi

Cấu hình retrieval	NDCG@10	Trả lời chính xác hoàn toàn	Đúng hoàn toàn hoặc một phần
Quy trình cơ sở	43,45	50,17%	91,03%
Kết hợp SEP	45,52	51,83%	89,70%
Kết hợp SEP và ColVec-8b	53,15	50,50%	93,69%

Kết quả chỉ ra rằng mặc dù chỉ số NDCG@10 tăng 22,3%, tỷ lệ câu trả lời chính xác hoàn toàn chỉ tăng nhẹ từ 50,17% lên 50,50%. Hiện tượng này bắt nguồn từ tính dư thừa bằng chứng của tập dữ liệu (trung bình 7,2 trang đúng/câu hỏi, trong khi mô hình sinh chỉ cần khoảng 2 trang để trả lời chính xác). Thực nghiệm thay thế mô hình sinh từ DeepSeek-V4-Flash sang GPT-5.2 khi giữ nguyên kết quả truy xuất cơ sở đã giúp tỷ lệ chính xác tăng vọt thêm 27,73% tuyệt đối (+55,3% tương đối). Phát hiện thực nghiệm quan trọng này khẳng định: trong kiến trúc RAG hiện tại của hệ thống, nút thắt hiệu năng nằm ở năng lực suy luận của mô hình sinh thay vì khâu truy xuất.

4. Chi phí và thời gian chạy

Để giải quyết bài toán thời gian lập chỉ mục ngoại tuyến kéo dài của ColVec-8b (chiếm 1h 58m), hệ thống áp dụng cơ chế lọc ứng viên *Kf* qua data discovery. Hiệu năng của cơ chế này được lượng hóa tại Bảng 6.

Bảng 6. Chất lượng nhánh Visual (ColVec-8b) theo số lượng tài liệu giữ lại Kf

Phạm vi	Độ phủ tài liệu	Số trang mỗi truy vấn	Tỉ lệ so với cả kho	NDCG@10 (ColVec-8b)
Kf = 3	86,92%	150,1	9%	50,83
Kf = 5	91,89%	247,0	15%	51,06
Kf = 10	96,36%	483,1	29%	51,89
Kf = 15	98,68%	682,5	41%	51,72
Kf = 20	99,01%	816,5	49%	51,62
Toàn bộ kho	100%	1.674	100%	51,63

Chỉ với ngưỡng *Kf* = 3 (tương đương việc chỉ cần xử lý 9% số trang của toàn kho), điểm NDCG@10 đã đạt 50,83, tiệm cận sát nút mức 51,63 khi mã hóa toàn bộ 100% kho tài liệu. Việc mở rộng *Kf* lên 20 làm khối lượng trang cần mã hóa tăng gấp 5,4 lần nhưng không mang lại sự khác biệt có ý nghĩa thống kê về độ chính xác.

Bảng 7 tổng hợp chi phí thời gian mô phỏng theo luồng on-demand kết hợp cache động dựa trên các hằng số đo thực tế trên phần cứng NVIDIA L4 (thời gian render: 147,9 ms/trang, mã hóa ColVec: 1,2 s/trang, MaxSim: 0,74 ms/trang, nạp mô hình: 77,2 s).

Bảng 7. Chi phí thời gian trên 302 câu hỏi (chữ đậm là cấu hình đề xuất)

Cấu hình	Chi phí offline	Thời gian tới câu trả lời đầu tiên (*T_first)*	Chi phí trung bình online (T_q)	p50	p95	Truy vấn chậm nhất
Quy trình cơ sở, lập chỉ mục toàn kho	1h 23m	1h 23m	21,7 ms	21,7 ms	—	—
Visual, lập chỉ mục toàn kho	40m 29s	40m 29s	1,27 s	1,27 s	—	—
Visual theo yêu cầu, Kf = 3	**1m 17s**	**5m 51s**	**7,88 s**	**0,16 s**	**35,25 s**	**4m 51s**
Visual theo yêu cầu, Kf = 10	1m 17s	14m 41s	8,18 s	0,40 s	0,48 s	13m 24s

Cấu hình đề xuất visual on-demand với *Kf* = 3 giúp cắt giảm thời gian khởi tạo phản hồi đầu tiên T_first từ 40 phút 29 giây xuống còn 5 phút 51 giây (nhanh hơn 6,9 lần so với lập chỉ mục visual toàn kho, và nhanh hơn 14 lần so với pipeline cơ sở). Về độ trễ phục vụ trực tuyến, trạng thái warm cache đạt tốc độ xử lý vượt trội ở mức phân vị trung vị p50 là 0,16 giây. Độ trễ trung bình tăng lên 7,88 giây chủ yếu do ảnh hưởng bởi các truy vấn cold-start đơn lẻ ở phân vị đuôi (p95 đạt 35,25 giây). Tốc độ này hoàn toàn có thể tiếp tục được tối ưu hóa thông qua các kỹ thuật suy luận theo lô (batching) và quantization cho mô hình.

Tổng hợp lại, kết quả của báo cáo gồm hai kết luận tách biệt. Về chất lượng, khi toàn bộ kho được mã hoá từ trước, cấu hình SEP kết hợp nhánh visual ColVec-8b nâng NDCG@10 từ 43,45 lên 53,15 điểm, trong đó nhánh visual đóng góp phần lớn, còn SEP đóng góp nhỏ và chỉ có ích với tài liệu ngắn. Về vận hành, nhánh visual chạy một

mình ở chế độ mã hoá theo yêu cầu với *Kf* = 3 vẫn giữ được 50,83 điểm, cao hơn quy trình cơ sở 7,38 điểm, trong khi thời gian chờ tới câu trả lời đầu tiên giảm từ hàng chục phút xuống khoảng 6 phút.

b. Hạn chế của giải pháp hiện tại

Giải pháp hiện tại có 4 hạn chế chính:

1. **Phạm vi hiệu quả của thuật toán SEP:** Do cấu trúc cây của SEP chỉ có hai cấp (Tài liệu và Trang), giải pháp mất dần tác dụng phân loại đối với các tài liệu kỹ thuật dài hàng trăm trang do tín hiệu ngữ cảnh cấp tài liệu bị loãng.
2. **Khả năng thương mại hóa và phụ thuộc định dạng của nhánh Visual:** Mô hình ColVec-8b hiện phát hành dưới giấy phép phi thương mại, gây rào cản pháp lý khi tích hợp vào sản phẩm. Ngoài ra, nhánh visual và bộ lọc data discovery hiện tại phụ thuộc chặt chẽ vào cấu trúc tệp PDF, chưa hỗ trợ trực tiếp các định dạng thuần hình ảnh hoặc tài liệu quét không có lớp văn bản gốc.
3. **Độ trễ ở phân vị đuôi:** Thời gian xử lý cho các truy vấn chạm vào tài liệu mới chưa có trong cache còn cao (truy vấn chậm nhất mất 4 phút 51 giây), đồng thời các kết quả đo đạc thời gian mới dừng lại ở mức mô phỏng tham số từ phần cứng GPU đơn lẻ.
4. **Sự không đồng bộ giữa chỉ số Retrieval và End-to-End:** Cải thiện vượt trội của khâu truy xuất chưa chuyển hóa tương xứng sang độ chính xác của câu trả lời cuối cùng do giới hạn của module trả lời câu hỏi (hiện tại chỉ là sử dụng LLM để hỏi đáp).

c. Hướng phát triển tiếp theo

Từ những hạn chế trên, dưới đây là những hướng phát triển tiếp

1. **Mở rộng cấu trúc phân cấp cho SEP:** Bổ sung thêm tầng cấu trúc trung gian (như chương, mục, tiểu mục) được trích xuất từ mô hình KDL nhằm duy trì hiệu năng của SEP trên các tài liệu dung lượng lớn.
2. **Thay thế mô hình Visual mã nguồn mở thương mại:** Thử nghiệm thay thế ColVec-8b bằng các mô hình thị giác mở có giấy phép thương mại (như ColPali mở rộng hoặc các biến thể Qwen-VL) kết hợp kỹ thuật lượng tử hóa trọng số (4-bit/8-bit quantization) và suy luận theo lô để triệt tiêu độ trễ phân vị đuôi.
3. **Thiết lập ngân sách ứng viên động:** Nghiên cứu, áp dụng cơ chế giới hạn cứng số lượng trang tối đa được phép mã hóa cho mỗi truy vấn, giúp tiết kiệm chi phí và thời gian chạy ở những bước mã hoá ở sau

4. **Tối ưu hóa module trả lời câu hỏi:** Phối hợp cùng nhóm phát triển AXIOM để xây dựng các giải pháp trả lời câu hỏi chuyên biệt có khả năng tiếp nhận và tổng hợp tốt hơn từ các bằng chứng đa phương thức đã truy xuất.

d. Kỹ năng và kiến thức thu thập được

Về kiến thức khoa học, em đã nắm vững toàn diện kiến trúc hệ thống truy xuất thông tin hiện đại cho doanh nghiệp, từ kỹ thuật truy xuất hỗn hợp (hybrid retrieval), cơ chế gộp điểm MaxP, đến mô hình tương tác đa phương thức. Rút ra bài học thực nghiệm sâu sắc về mối quan hệ giữa tối ưu hóa truy xuất và hiệu quả sinh ngôn ngữ cuối cùng.

Về kỹ năng kỹ thuật, em làm chủ kỹ năng xây dựng phần mềm chuẩn công nghiệp theo kiến trúc module plugin trong cấu trúc monorepo phức tạp. Đồng thời, thành thạo hơn phương pháp luận thiết kế thực nghiệm khoa học có đối chứng và nâng cao năng lực triển khai, phân bổ tài nguyên tính toán trên các hạ tầng như Colab, Kaggle GPU.

TÀI LIỆU THAM KHẢO

[1]A. Loison, Q. Macé, A. Edy, V. Xing, T. Balough, G. Moreira, B. Liu, M. Faysse, C. Hudelot, G. Viaud, "ViDoRe V3: A Comprehensive Evaluation of Retrieval Augmented Generation in Complex Real-World Scenarios," arXiv preprint arXiv:2601.08620, 2026.

[2]H. Chen, Y. Yang, Y. Li, M. Zhang, B. Hu, M. Zhang, "Beyond Chunking: Discourse-Aware Hierarchical Retrieval for Long Document Question Answering," arXiv preprint arXiv:2506.06313, 2025.

[3]X. Chen et al., "DAT: Dynamic Alpha Tuning for Adaptive Hybrid Retrieval," arXiv preprint arXiv:2503.23013, 2025.

[4]M. Xu, G. Moreira, R. Ak, R. Osmulski, Y. Babakhin, Z. Yu, B. Schifferer, E. Oldridge (NVIDIA), "Llama Nemoretriever Colembed: Top-Performing Text-Image Retrieval Model," arXiv preprint arXiv:2507.05513, 2025.

[5]webAI, "webAI-ColVec1.1: Vision-Language Document Retrieval Model," Technical Report, Model License Non-Commercial v1.0, 2025.

[6]M. Faysse et al., "ColPali: Efficient Document Retrieval with Vision Language Models," arXiv preprint arXiv:2407.01449, 2024.

[7]X. H. Lù, "BM25S: Orders of Magnitude Faster Lexical Search via Eager Sparse Scoring," arXiv preprint arXiv:2407.03618, 2024.

[8]F. Diaz, "Regularizing Query-Based Retrieval Scores," Information Retrieval, vol. 10, no. 6, pp. 531-562, 2007.

[9]G.-H. Cho, Y. Lee, K. Jeong (NAVER), "Inference-Free Multimodal Learned Sparse Retrieval for Production-Scale Visual Document Search," arXiv preprint arXiv:2605.30917, 2026.

[10]Y. Shen et al., "MMDocIR: Benchmarking Multi-Modal Retrieval for Long Documents," in Findings of EMNLP 2025, pp. 1201-1215, 2025.

[11]S. Barnett et al., "Is Semantic Chunking Worth the Computational Cost?," in Proceedings of NAACL 2025, pp. 312-325, 2025.

[12]P. Sarthi et al., "RAPTOR: Recursive Abstractive Processing for Tree-Organized Retrieval," in ICLR 2024, 2024.

[13]L. Ouyang et al., "OmniDocBench: Benchmarking Diverse PDF Document Parsing with Comprehensive Annotations," arXiv preprint arXiv:2412.07626, 2025.

[14]NVIDIA, "Llama-Nemotron-Rerank-VL-1B-v2 Model Card," Hugging Face, 2025.

[15]P. Tilli, M. Mesgar, "Beyond Bag-of-Patches: Learning Global Layout via Textual Supervision for Late-Interaction Visual Document Retrieval," arXiv preprint arXiv:2605.08421, 2026.

[16]A. Georgiou, "Spatially-Grounded Document Retrieval via Patch-to-Region Relevance Propagation," arXiv preprint arXiv:2512.02660, 2026.

[17]A. Abdallah, M. Abdalla, M. Ali, A. Jatowt, "Argus-Retriever: Vision-LLM Late-Interaction Retrieval with Region-Aware Query-Conditioned MoE for Visual Document Retrieval," arXiv preprint arXiv:2606.04300, 2026.

[18]H. Sun, Y. Hou, J. Guo, B. Wang, C. Yang, J. Ni, Y. Zhang, "Unveil: Unified Visual-Textual Integration and Distillation for Multi-modal Document Retrieval," arXiv preprint arXiv:2605.24530, 2026.

[19]T. Guan, H. Wang, W. Shen, X. Yang, "LightSTAR: Efficient Visual Document Retrieval via Lightweight Selection with Vision-Adaptive Refinement," arXiv preprint arXiv:2606.23539, 2026.

[20]Z. Wang, D. Ma, H. Zhong, J. Li, W. Zhang, B. Wang, C. He, "AgenticOCR: Parsing Only What You Need for Efficient Retrieval-Augmented Generation," arXiv preprint arXiv:2602.24134, 2026.

[21]H. Yao, J. Zhong, N. Lian, J. Wang, "DocMemo: Dynamic Evidence Discovery via Probabilistic Memory-Guided Retrieval for Multi-Modal Document Understanding," arXiv preprint arXiv:2608.07067, 2026.

Ý kiến đánh giá:

Điểm số: …… Điểm chữ: ……

Hà Nội, ngày …… tháng …… năm 20……

Giảng viên đánh giá

(Ký, ghi rõ họ tên)